

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ
КАФЕДРА МАТЕМАТИЧЕСКОГО МОДЕЛИРОВАНИЯ И АНАЛИЗА ДАННЫХ

Румянцев
Андрей Кириллович

**Статистическое оценивание параметров линейной
регрессии с выбросами при наличии группирования
наблюдений**

Дипломная работа

Научный руководитель:
зав. кафедрой ММАД,
канд. физ.-мат. наук, доцент
Бодягин Игорь Александрович

Допущена к защите

«__» _____ 2019 г.

Зав. кафедрой ММАД,

канд. физ.-мат наук, доцент И.А. Бодягин

Минск, 2019

Содержание

ВВЕДЕНИЕ	6
1 Математическая модель линейной регрессии с выбросами при наличии группирования наблюдений	8
2 Способы оценивания параметров линейной регрессии с выбросами	9
2.1 Метод наименьших квадратов	9
2.2 М-оценки	10
3 Статистическое оценивание параметров линейной регрессии с выбросами при наличии группирования наблюдений	12
3.1 Оценки максимального правдоподобия параметров линейной регрессии при наличии группирования наблюдений	12
3.1.1 Метод секущих	14
3.2 Переклассификация выборки	15
3.2.1 Метод K -ближайших соседей	16
3.2.2 Переклассификация с использованием Локального уровня выброса и Случайного леса	16
3.3 Альтернативные оценки параметров модели	18
3.4 Полиномиальная регрессия	19
4 Компьютерные эксперименты	21
4.1 График рассеяния зависимой переменной и регрессоров	21
4.2 Вариации оценок МНК и М-оценок в случае линейной регрессии с выбросами	22
4.3 Вариации оценок без переклассификации	23
4.4 Графики рассеяния оценок в случае использования метода K -ближайших соседей для переклассификации	24
4.5 Сравнение оценок при переклассификации методом K -ближайших соседей с оценками без переклассификации	25
4.6 Сравнительный анализ оценок максимального правдоподобия с альтернативной	26
4.6.1 Эксперимент с изменением объема выборки	26
4.6.2 Эксперимент с полиномиальной регрессией	27
4.7 Эксперименты с изменением уровня переклассификации выборки для метода K -ближайших соседей	28
4.8 Эксперименты с изменением K для Local outlier factor, используемого в переклассификации	29
4.9 Влияние переклассификации методом LOF на вариации оценок	31
Заключение	32

Список Литературы	33
Приложение	35

РЕФЕРАТ

Дипломная страница, 37.с, 11 рис., 15 источников.

Ключевые слова: ЛИНЕЙНАЯ РЕГРЕССИЯ, АНОМАЛЬНЫЕ НАБЛЮДЕНИЯ, ГРУППИРОВАННЫЕ НАБЛЮДЕНИЯ, ОЦЕНКИ МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ.

Объект исследования: линейная регрессия с аномальными наблюдениями при наличии группированных наблюдений. Оценки ее параметров.

Цель работы: предложить способ оценивания параметров линейной регрессии с аномальными наблюдениями при наличии группированных наблюдений, устойчивый к аномальным наблюдениям.

Основные методы исследования: оценки максимального правдоподобия, метод секущих решения систем нелинейных уравнений, локальный уровень выброса, случайный лес.

Результат: Были предложены алгоритмы оценивания параметров линейной и полиномиальной регрессии с аномальными наблюдениями при наличии группирования выборки.

Рэферат

Дыпломная праца, 37 старонак, 11 малюнкаў, 15 крыніц.

Ключавыя словы: ЛІНЕЙНАЯ РЭГРЭСІЯ, АСТАНЦЫ, КЛАСТАРЫЗАЦЫЯ ВЫБАРКІ, АЦЭНКІ МАКСІМАЛЬНАГА ПРАЎДАПАДАБЕНСТВА.

Аб’ект даследавання: лінейная рэгрэсія з анамальнымі назіраннямі пры наяўнасці групування назіранняў. Ацэнкі яе параметраў.

Мэта працы: прапанаваць спосаб ацэньвання параметраў лінейнай рэгрэсіі з анамальнымі назіраннямі пры наяўнасці групування назіранняў, ўстойлівы да анамальных назіранняў.

Асноўныя метады даследавання: ацэнкі максімальнага праўдападабенства, метады хорд рашэння сістэм нелінейных раўнанняў, лакальны ўзровень выкіду, выпадковы лес.

Вынік: Былі прапанаваны алгарытмы ацэньвання параметраў лінейнай і паліномнай рэгрэсіі з анамальнымі назіраннямі пры наяўнасці групування выбаркі.

ABSTRACT

Graduate work, 37 pages, 11 figures., 15 sources.

Key words: LINEAR REGRESSION, OUTLIERS, SAMPLE CLUSTERING, MAXIMUM LIKELIHOOD ESTIMATES.

Object of study: linear regression with outliers in the presense of clustered observations . Estimates of its parameters.

Objective: propose a robust method of linear regression with outliers in the presense of clustered observations parameters estimation.

Methods of research: maximum likelihood estimates, secant method of solving nonlinear equations , local outlier factor, random forest.

Result: estimating algorithms of linear and polynomial regression with outliers in the presense of clustered observations parameters were designed.

ВВЕДЕНИЕ

В математической статистике широко используется регрессионная модель, т.е. такая модель, которая отражает зависимость некоторой величины от некоторых других независимых величин. Одним из примеров использования такой модели является автономный мониторинг целостности приемника (RAIM) системы глобального позиционирования (GPS). Это технология, которая разработана для оценки целостности сигналов GPS. Такая система очень важна в приложениях авиационной и морской навигации, где безопасность приложений GPS критична [13].

В случае когда наблюдаемые данные полностью соответствуют модельным предположениям, в литературе известны несколько методов оценивания модельных параметров, такие как метод наименьших квадратов, метод максимального правдоподобия и др., которые дают состоятельные и несмещенные оценки. К сожалению, если наблюдаемые данные содержат искажения (т.е. данные, не удовлетворяющие модельным предположениям), то такие классические методы начинают давать смещенные и несостоятельные оценки, а иногда и вовсе неприменимы на практике. Поэтому актуальной является задача разработки новых оценок, учитывающих наличие конкретного вида искажения.

В качестве искажений данных в литературе часто рассматриваются аномальные наблюдения, цензурирование, пропуски и др [6]. В рамках данной дипломной работы, будет рассмотрена модель регрессии с аномальными наблюдениями. Аномальными наблюдениями (выбросами) называются такие наблюдения, которые описываются распределением вероятностей, отличным от распределения вероятностей истинных значений. Аномальные наблюдения могут возникать по разным причинам: из-за ошибки измерения, из-за необычной природы входных данных и др [3].

В прошлом веке в работах Хьюбера была заложена теория робастного оценивания, т. е. такого оценивания, которое исключает влияние искажений в выборке на результат оценивания.

В [1] были предложены следующие робастные оценки:

- М-Оценки;
- R-Оценки;
- L-Оценки.

М-оценки – некоторое подобие оценок максимального правдоподобия (ММП-оценки - частный случай), L-оценки строятся на основе линейных комбинаций порядковых статистик, R-оценки – на основе ранговых статистик.

Такие случаи, когда зависимые переменные наблюдаются с выбросами или с пропусками, хорошо исследованы [3]. Более сложный случай, когда вместо содержащих выбросы значений зависимой переменной наблюдаются номера классов(интервалов), в которые попадают эти наблюдения [11], изучен не так хорошо и поэтому представляет больший интерес.

В дипломной работе мы будем рассматривать модель линейной регрессии с аномальными наблюдениями при наличии группирования выборки.

1 Математическая модель линейной регрессии с выбросами при наличии группирования наблюдений

Рассмотрим модель линейной регрессии:

$$y_i = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \dots \\ \beta_n \end{pmatrix} \times \begin{pmatrix} 1 \\ x_{i1} \\ \dots \\ x_{in} \end{pmatrix}^T + \varepsilon_i, \quad (1)$$

$$y_i = f(x_i, \beta) + \varepsilon_i, \quad (2)$$

$$f(x_i, \beta) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_n x_{in}. \quad (3)$$

Здесь y_i – зависимая переменная, $x_i = (x_{i1}, x_{i2}, \dots, x_{in})$ – вектор регрессоров, $\{\beta_k, k = \overline{0, n}\}$ – коэффициенты линейной регрессии, а ε_i – случайная ошибка i -го эксперимента, распределение которой подчиняется нормальному закону с нулевым математическим ожиданием и дисперсией σ^2 , N – объем выборки. Согласно (2) каждый y_i принадлежит нормальному распределению:

$$y_i = f(x_i, \beta) + \varepsilon_i \sim \mathcal{N}(f(x_i, \beta), \sigma^2). \quad (4)$$

Предполагается, что выборка содержит выбросы, описываемые следующим соотношением.

$$y_i^{\tilde{\varepsilon}} = (\xi_i) y_i + (1 - \xi_i) \eta_i, \quad (5)$$

где ξ_i принимает значение, равное 1, с вероятностью $1 - \tilde{\varepsilon}$ и значение, равное 0, с вероятностью $\tilde{\varepsilon}$:

$$\begin{cases} P\{\xi_i = 0\} = \tilde{\varepsilon}, \\ P\{\xi_i = 1\} = 1 - \tilde{\varepsilon}, \end{cases} \quad (6)$$

η_i -случайная величина из некоторого вообще говоря неизвестного распределения.

Параметр ξ_i имеет следующий содержательный смысл: если $\xi_i = 0$, то вместо истинного значения мы наблюдаем выброс, если $\xi_i = 1$, то наблюдается истинное значение. Переменную $\tilde{\varepsilon}$ будем называть долей аномальных наблюдений. Величины ξ_i, x_i и η_i являются независимыми.

Пусть множество значений функции регрессии, т.е. множество \mathbb{R} , разбито на k непересекающихся полуинтервалов:

$$\mathbb{R} = (-\infty, a_1] \cup (a_1, a_2] \cup \dots \cup (a_{k-1}, +\infty). \quad (7)$$

Полученные полуинтервалы будем обозначать: ν_0, \dots, ν_{k-1} .

Предполагается, что каждый раз вместо истинного значения зависимой переменной y_i наблюдается только номер интервала, в который это наблюдение попало. Тогда для каждого y_i будем наблюдать лишь номер полуинтервала μ_i , в который он попал.

$$\mu_i = j, \text{ если } y_i \in \nu_j. \quad (8)$$

В таком случае принято говорить, что имеет место группирование наблюдений, а сами наблюдения называются группированными [3].

В работе рассматривается задача оценивания параметров линейной регрессии с аномальными наблюдениями при наличии группирования наблюдений.

2 Способы оценивания параметров линейной регрессии с выбросами

Для модели регрессии (1), то есть для классической модели линейной регрессии, существует несколько способов оценивания параметров. Далее приведены некоторые из них.

2.1 Метод наименьших квадратов

Метод наименьших квадратов строится из предположения, что ошибки подчиняются нормальному закону распределения вероятностей:

$$L\{\varepsilon_i\} = N_1(0, \sigma^2), i = \overline{1, n}. \quad (9)$$

Исходя из предположения (9) можно построить логарифмическую функцию правдоподобия. В силу (2) имеем:

$$L\{y_i\} = N_1(f(x_i; \beta), \sigma^2). \quad (10)$$

Логарифмическая функция правдоподобия выглядит так[2]:

$$l(\beta) = \ln \prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y_i - f(x_i; \beta))^2}{2\sigma^2}} \right) = -\frac{1}{2}n \ln 2\pi\sigma^2 - \frac{1}{2\sigma^2}R^2(\beta), \quad (11)$$

$$R^2(\beta) = \sum_{i=1}^n (\delta y_i)^2 = \sum_{i=1}^n (y_i - f(x_i, \beta))^2 \geq 0. \quad (12)$$

Оценка методом наименьших квадратов называется такая оценка, которая минимизирует выражение (12) такого:

$$\hat{\beta} = \arg \min_{\beta} R^2(\beta). \quad (13)$$

Метод наименьших квадратов не считается робастным способом оценивания параметров линейной регрессии. Для иллюстрации этого был проведен компьютерный эксперимент (раздел 4.2), в результате которого вариации оценок не уменьшались с увеличением объема выборки, в которой присутствовали аномальные наблюдения. Это означает, что построенные оценки не являются состоятельными в случае, если в данных присутствуют выбросы.

2.2 М-оценки

М-оценки являются робастным способом оценивания параметров линейной регрессии с аномальными наблюдениями. Швейцарский статистик П.Хьюбер предложил использовать М-оценки [2], которые являются решениями экстремальных задач вида:

$$\sum_{i=1}^n \phi(x_i; \beta) \rightarrow \min_{\beta}, \quad (14)$$

где $\phi(\cdot; \beta)$ -некоторая функция, определяющая конкретный тип оценок и их точность.

Очевидно, что $\phi(\cdot; \beta) \equiv -\ln p(\cdot; \beta)$ дает обычную оценку максимального правдоподобия, построенную по модели без выбросов (1).

Рассмотрим теперь некоторые способы выбора функции $\phi(\cdot; \beta)$ для решения экстремальной задачи в М-оценках.

Для начала определим:

$$u_i = y_i^{\tilde{}} - (\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_n x_{in}). \quad (15)$$

Тогда существует такие методы[4]:

Способы выбора $\phi(\cdot; \beta)$	
Метод	Целевая функция
Метод Наименьших Квадратов	$\phi(\cdot; \beta)_{OLS} = u^2$
Хьюбера	$\phi(\cdot; \beta)_H = \begin{cases} \frac{1}{2}u^2, u \leq k, \\ k u - \frac{1}{2}k^2, u > k \end{cases}$
Биквадратный	$\phi(\cdot; \beta)_B = \begin{cases} \frac{k^2}{6}(1 - [1 - (\frac{u}{k})^2]^3), u \leq k \\ \frac{k^2}{6}, u > k \end{cases}$

В разделе 4.2 приведено сравнение М-оценок с целевой функцией Хьюбера с оценками по Методу наименьших квадратов. Сравнение показало отличие поведения вариаций робастных М-оценок (вариации уменьшались) от вариаций оценок МНК (вариации не уменьшались) при увеличении объема выборки с искажениями.

3 Статистическое оценивание параметров линейной регрессии с выбросами при наличии группирования наблюдений

3.1 Оценки максимального правдоподобия параметров линейной регрессии при наличии группирования наблюдений

Введем обозначение для функции распределения стандартного нормального закона:

$$\Phi(x) = \frac{1}{\sqrt{2\sigma}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt. \quad (16)$$

Тогда функцию распределения нормального закона с параметрами μ, σ^2 можно представить как:

$$F(x) = \Phi\left(\frac{x - \mu}{\sigma}\right), \quad (17)$$

где $\sigma = \sqrt{\sigma^2}$.
Обозначим:

$$\text{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2} dt. \quad (18)$$

Тогда:

$$\Phi(x) = \frac{1}{2} \left[1 + \text{erf}\left(\frac{x}{\sqrt{2}}\right) \right]. \quad (19)$$

Подставив полученные выражения в (17) получим:

$$F(x) = \frac{1}{2} \left[1 + \text{erf}\left(\frac{x - \mu}{\sqrt{2}\sigma}\right) \right]. \quad (20)$$

При модельных предположениях (4) вероятность попадания y_i в полуинтервал ν_j равна:

$$\begin{aligned} P\{y_i \in \nu_j\} &= F_{y_i}(a_{j+1}) - F_{y_i}(a_j) = \\ &= \begin{cases} \frac{1}{2}(\text{erf}(\frac{a_{j+1}-f(x_i,\beta)}{\sqrt{2}\sigma}) - \text{erf}(\frac{a_j-f(x_i,\beta)}{\sqrt{2}\sigma})), & j = \overline{1, k-2} \\ \frac{1}{2}(1 + \text{erf}(\frac{a_1-f(x_i,\beta)}{\sqrt{2}\sigma})), & j = 0 \\ -\frac{1}{2}(1 + \text{erf}(\frac{a_{k-1}-f(x_i,\beta)}{\sqrt{2}\sigma})), & j = k-1 \end{cases}. \end{aligned} \quad (21)$$

Понятно, что:

$$P(\mu_i = j) = P(y_i \in \nu_{\mu_i}). \quad (22)$$

Решается задача статистического оценивания параметров модели (1) $\{\beta_k, k = \overline{0, n}\}$ по известным группированным наблюдениям. Здесь наличие аномальных наблюдений не учитывается.

Для этого построим функцию правдоподобия:

$$l(\beta, \sigma^2, \mu_1, \dots, \mu_N) = \sum_{i=1}^N \ln(P(y_i \in \nu_{\mu_i})) = \quad (23)$$

$$= \sum_{i=1}^N \ln \begin{cases} \frac{1}{2}(\operatorname{erf}(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma})), & \mu_i = \overline{1, k-2}; \\ \frac{1}{2}(1 + \operatorname{erf}(\frac{a_1-f(x_i, \beta)}{\sqrt{2}\sigma})), & \mu_i = 0; \\ -\frac{1}{2}(1 + \operatorname{erf}(\frac{a_{k-1}-f(x_i, \beta)}{\sqrt{2}\sigma})), & \mu_i = k-1, \end{cases} \quad (24)$$

где:

$$\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2} dt. \quad (25)$$

Для максимизации функции правдоподобия решим систему уравнений:

$$\frac{\delta l}{\delta \beta} = 0_{n+1}, \quad (26)$$

где:

$$\begin{aligned} \frac{\delta l}{\delta \beta} &= \frac{\delta \sum_{i=1}^N \ln P(y_i \in \nu_{\mu_i})}{\delta \beta} = \\ &= \frac{\delta \sum_{i=1}^N \ln(\frac{1}{2}(\operatorname{erf}(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma})))}{\delta \beta} = \\ &= \sum_{i=1}^N \left((1 - (\delta_{\mu_i 0} + \delta_{\mu_i k-1})) \frac{(\operatorname{erf}'(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}'(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))}{(\operatorname{erf}(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))} + \right. \\ &\quad \left. + (\delta_{\mu_i 0} - \delta_{\mu_i k-1}) \frac{\operatorname{erf}'(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma})}{(1 + \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))} \right) (-1) \frac{\delta f(x_i, \beta)}{\delta \beta} = \quad (27) \end{aligned}$$

$$= - \sum_{i=1}^N \begin{pmatrix} 1 \\ x_{i1} \\ \dots \\ x_{in} \end{pmatrix} \times \left((1 - (\delta_{\mu_i 0} + \delta_{\mu_i k-1})) \frac{(\operatorname{erf}'(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}'(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))}{(\operatorname{erf}(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))} + \right. \\ \left. + (\delta_{\mu_i 0} - \delta_{\mu_i k-1}) \frac{\operatorname{erf}'(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma})}{(1 + \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))} \right).$$

$\delta_{ij} = \{1, i = j; 0, i \neq j\}$ - символ Кронекера, $0_{n+1} = (0, \dots, 0)^T$ - вектор размерности $n + 1$ состоящий из одних нулей.

В полученном уравнении используется функция $\operatorname{erf}(x)$ и ее производная. Для вычисления значений этой функции существует таблица значений и приближение аналитической функцией [7]. Будем использовать приближение для функции $\operatorname{erf}(x)$:

$$(\operatorname{erf}(x))^2 \approx 1 - \exp(-x^2 \frac{\frac{4}{\pi} + ax^2}{1 + ax^2}), \quad (28)$$

$$a = \frac{8}{3\pi} \frac{3 - \pi}{\pi - 4}.$$

Оно считается достаточно точным для x близких к 0 и к ∞ [7].

Найдем производную для этого приближения:

$$\operatorname{erf}'(x) = \exp(-x^2 \frac{\frac{4}{\pi} + ax^2}{1 + ax^2}) \frac{-2x \frac{\frac{4}{\pi} + ax^2}{1 + ax^2} + (2ax^3) \frac{\frac{4}{\pi} + ax^2}{1 + ax^2} - \frac{2ax^3}{1 + ax^2}}{2\sqrt{1 - \exp(-x^2 \frac{\frac{4}{\pi} + ax^2}{1 + ax^2})}}. \quad (29)$$

Подставив выражения (28)-(29) в (26), получим уравнение, которое будем решать методом секущих.

3.1.1 Метод секущих

Так как мы не можем привести систему $\frac{\delta l}{\delta \beta} = 0$ к виду, удобному для итерации, то нам придется искать ее нули с помощью метода секущих [8]. Введем вектор ошибки $\tilde{\varepsilon}^{(k)} = \beta^* - \beta^{(k)}$. Тогда для определения вектора ошибки имеем:

$$\frac{\delta l(\beta^{(k)} + \tilde{\varepsilon}^{(k)})}{\delta \beta} = 0. \quad (30)$$

Строя разложение левой части по формуле Тейлора и ограничиваясь лишь линейными членами[8], будем иметь систему:

$$\frac{\delta}{\delta\beta} \frac{\delta l(\beta^{(k)})}{\delta\beta} \Delta\beta^{(k)} = -\frac{\delta l(\beta^{(k)})}{\delta\beta}. \quad (31)$$

Вторая производная функции l приближается с помощью выражения:

$$\frac{\delta}{\delta\beta_j} \frac{\delta l(\beta_1^{(k)}, \dots, \beta_n^{(k)})}{\delta\beta} \approx \frac{\frac{\delta l(\beta_1^{(k)}, \dots, \beta_j^{(k)}, \dots, \beta_n^{(k)})}{\delta\beta}(\beta^{(k)}) - \frac{\delta l(\beta_1^{(k)}, \dots, \beta_j^{(k-1)}, \dots, \beta_n^{(k)})}{\delta\beta}(\beta^{(k)})}{\beta_j^{(k)} - \beta_j^{(k-1)}}. \quad (32)$$

Если матрица $\frac{\delta}{\delta\beta} \frac{\delta l(\beta^{(k)})}{\delta\beta}$ невырожденная (а в нашем случае она диагональная), то из этой системы можно единственным образом найти $\Delta\beta^{(k)}$ и построить приближение:

$$\beta^{(k+1)} = \beta^{(k)} + \Delta\beta^{(k)}. \quad (33)$$

Согласно [8] метод секущих в общем случае обладает квадратичной скоростью сходимости.

Одним из минусов метода секущих является то, что он требует два начальных приближения, т.е. отрезок, где, как мы предполагаем, находится точное значение параметров регрессии. Условием остановки метода секущих будем задавать такое, что разница значений логарифмической функции правдоподобия l на двух соседних итерациях не более некоторой заданной величины. Теперь имеем нули производной функции l , а также ее значения на границе отрезка $[a, b]$. Переберем эти значения и таким образом найдем значение вектора $\hat{\beta}$, где она достигает своего максимального значения.

3.2 Переклассификация выборки

Отметим, что в исходной постановке задачи данные содержат аномальные наблюдения, которые тоже подвергаются группированию. Наличие аномальных наблюдений в исходных данных портит точность метода максимального правдоподобия (см. раздел 4.9). Для уменьшения влияния выбросов будем использовать переклассификацию выборки. Идея заключается в том, что аномальные наблюдения с большей вероятностью попадают не в те интервалы, в которые попадают истинные наблюдения. При этом переклассификация может помочь отнести аномальные наблюдения к истинным классам и улучшить качество оценивания.

В ходе выполнения дипломной работы было испробовано несколько способов переклассификации выборки. Один из них: метод K -ближайших соседей.

3.2.1 Метод K -ближайших соседей

На первом этапе для каждого вектора x_i задан класс μ_i : т.е. пара (x_i, μ_i) . Далее выполним переклассификацию выборки. Для этого построим новую выборку такого же объема N . Пройдемся по каждому элементу (x_i, μ_i) выборки и для этого наблюдения построим новое:

$$(x_i, \check{\mu}_i), \quad (34)$$

где $\check{\mu}_i$ получен по методу K -ближайших соседей[14].

$$\check{\mu}_i = \arg \max_j \sum_{k \in V_i, k \neq i} \delta_{\mu_k j}, \quad (35)$$

где V_i множество индексов l первых K векторов x_l , отсортированных по возрастанию расстояния до вектора x_i .

После переклассификации выборки, к ней применяется функция правдоподобия (23), только теперь с использованием новых классов $\check{\mu}_i$ вместо μ_i . Она аналогично максимизируется и в итоге находится новая оценка параметров $\hat{\beta}$.

В ходе экспериментов (раздел 4) оказалось, что метод K ближайших соседей исправляет очень мало ошибочных классов в выборке, поэтому было решено использовать другой метод переклассификации.

3.2.2 Переклассификация с использованием Локального уровня выброса и Случайного леса

Идея метода заключается в следующем: определим в выборке такие наблюдения, которые, вероятно, являются аномальными с помощью какого-либо способа. После этого выберем наблюдения, которые не определились как аномальные. Обучим на полученных наблюдениях классификатор. После этого с помощью обученного классификатора переклассифицируем те наблюдения, которые определились как аномальные. В итоге получим выборку, которую будем использовать при решении уравнения (23) [12].

Для определения аномальных наблюдений можно использовать Локальный уровень выброса. Метод был предложен Маркусом М. Бройнигом, Гансом-Петер Кейгелем, Реймондом Т. НГ и Ёргом Сандером в 2000 году. Аномальные наблюдения находятся с помощью измерения локального отклонения точек с учётом их соседей. Метод основан на концепте локальной плотности достижимости, где локальная плотность достижимости вычисляется с учётом ближайших K соседей, расстояние до

которых используется для вычисления плотности. Сравнивая локальную плотность точки с локальной плотностью соседей можно определять точки, которые обладают значительно меньшей локальной плотностью по сравнению с соседями. Такие точки будем считать выбросами.

Пусть x_i является некоторой точкой выборки. Определим $\rho(x_i, x_l)$ – расстояние от точки x_i до точки x_l (будем использовать Евклидову метрику), $\rho_k(x_i)$ – расстояние от точки x_i до её K -го соседа. Аналогично методу K -ближайших соседей обозначим множество индексов k первых K векторов x_k , отсортированных по возрастанию расстояния до вектора x_i через V_i . Используя введенные величины зададим:

$$\hat{\rho}_k(x_i, x_l) = \max\{\rho_k(x_l), \rho(x_i, x_l)\}. \quad (36)$$

Такую величину можно интерпретировать как истинное расстояние от точки x_l до точки x_i если x_l не входит в её K ближайших соседей или расстояние до точки $x_{V_{l_K}}$ в противном случае. Данная величина введена для того, чтобы более стабильно вычислять расстояние для тех значений, которые входят в K -ближайших соседей точки x_l .

Заметим, что введенная величина не обладает свойством симметричности.

Локальную плотность достижимости зададим выражением:

$$\text{lrd}_k(x_i) = 1 / \left(\frac{\sum_{l \in V_i} \hat{\rho}_k(x_i, x_l)}{|V_i|} \right). \quad (37)$$

Теперь можно задать величину:

$$\text{LOF}_k(x_i) = \frac{\sum_{l \in V_i} \frac{\text{lrd}_k(x_l)}{\text{lrd}_k(x_i)}}{|V_i|}. \quad (38)$$

Она является средней локальной плотностью достижимости соседей точки x_i по отношению к своей локальной плотности достижимости точки x_i .

По полученному значению можно судить [12], является ли наблюдение x_i выбросом или нет:

- $\text{LOF}_k(x_i) \sim 1$ – означает, что у наблюдения x_i такая же плотность как и у его соседей;
- $\text{LOF}_k(x_i) < 1$ – означает, что у наблюдения x_i большая плотность чем у его соседей (наблюдение - истинное);

- $\text{LOF}_k(x_i) > 1$ – означает, что у наблюдения x_i меньшая плотность чем у его соседей (наблюдение - выброс).

Таким образом найдем аномальные наблюдения в выборке.

Теперь обучим классификатор на предполагаемых истинных значениях выборки. Воспользуемся алгоритмом классификации на основе Случайного леса [15]. Построим по выборке несколько деревьев решений. Применим обученный классификатор к каждому аномальному наблюдению. Тот класс, к которому отнесло наибольшее количество построенных деревьев решений будем считать истинным классом данного аномального наблюдения.

В ходе компьютерных экспериментов была построена таблица подходящих значений K для заданной длины интервала и объема выборки (раздел 4.8 таблица 4). В целом, данный метод показал хорошие результаты и может быть использован на практике для улучшения результатов оценивания методом максимального правдоподобия.

3.3 Альтернативные оценки параметров модели

Рассмотрим альтернативный метод оценивания параметров модели линейной регрессии с выбросами при наличии группирования наблюдений, основанный на замене группированных наблюдений серединами соответствующих интервалов. Такой метод встречается в литературе, например в [9].

Метод заключается в следующем: пусть имеется μ_i - номер полуинтервала, в который попало очередное наблюдение y_i . Ему соответствует полуинтервал ν_{μ_i} (из (8)), т.е. полуинтервал:

$$y_i \in (a_{\nu_{\mu_i}}, a_{\nu_{\mu_i}+1}], i = \overline{1, N} \quad (39)$$

(считаем что $a_1 < y_i < a_{k-1}, i = \overline{1, N}$, т.е $1 \leq \mu_i \leq k - 2$).

Найдем центральную точку этого интервала, т.е. точку

$$\check{y}_i = \frac{a_{\nu_{\mu_i}} + a_{\nu_{\mu_i}+1}}{2}. \quad (40)$$

Построим для всех значений функции регрессии y_i значения \check{y}_i . Будем использовать в качестве значений функции регрессии полученные значения \check{y}_i , а в качестве регрессоров x_i и построим МНК оценки параметров β .

Теперь имеет три вида оценок: оценки максимального правдоподобия, оценки максимального правдоподобия с переклассификацией, МНК по серединам интервалов. В разделе 4.6 было проведено сравнение этих

трех методов. Оценки максимального правдоподобия с переклассификацией показали самые лучшие результаты.

3.4 Полиномиальная регрессия

Введем теперь модель полиномиальной регрессии.

$$\begin{aligned} y_i &= \beta_0 + \beta_1 x_{i1}^1 + \beta_2 x_{i2}^2 + \cdots + \beta_n x_{in}^n + \varepsilon_i, i = \overline{1, N}, \\ y_i &= \sum_{l=1}^n x_{il}^{l-1} + \varepsilon_i, i = \overline{1, N}, \\ y_i &= f(x_i, \beta) + \varepsilon_i, \\ f(x_i, \beta) &= \beta_0 + \beta_1 x_{i1}^1 + \beta_2 x_{i2}^2 + \cdots + \beta_n x_{in}^n. \end{aligned} \quad (41)$$

В случае полиномиальной регрессии также справедливо:

$$y_i \sim \mathcal{N}(f(x_i, \beta), \sigma^2). \quad (42)$$

Поскольку оценки строились путём максимизирования функции:

$$l(\beta, \sigma^2, \nu_0, \dots, \nu_{k-1}) = \sum_{i=1}^N \ln(P(y_i \in \nu_{\mu_i})) = \quad (43)$$

$$= \sum_{i=1}^N \ln \begin{cases} \frac{1}{2}(\operatorname{erf}(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma})), & \mu_i = \overline{1, k-2}, \\ \frac{1}{2}(1 + \operatorname{erf}(\frac{a_1-f(x_i, \beta)}{\sqrt{2}\sigma})), & \mu_i = 0, \\ \frac{1}{2}(1 + \operatorname{erf}(\frac{a_{k-1}-f(x_i, \beta)}{\sqrt{2}\sigma})), & \mu_i = k-1, \end{cases} \quad (44)$$

а функция правдоподобия максимизировалась путём решения системы уравнений:

$$\frac{\delta l}{\delta \beta} = 0, \quad (45)$$

которая примет вид:

$$\begin{aligned} \frac{\delta l}{\delta \beta} &= \frac{\delta \sum_{i=1}^N \ln P(y_i \in \nu_{\mu_i})}{\delta \beta} = \\ &= \frac{\delta \sum_{i=1}^N \ln(\frac{1}{2}(\operatorname{erf}(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma})))}{\delta \beta} = \\ &= \sum_{i=1}^N \left((1 - (\delta_{\mu_i 0} + \delta_{\mu_i k-1})) \frac{(\operatorname{erf}'(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}'(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma})))}{(\operatorname{erf}(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))} + \right. \\ &\quad \left. + (\delta_{\mu_i 0} - \delta_{\mu_i k-1}) \frac{\operatorname{erf}'(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma})}{(1 + \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))} \right) (-1) \frac{\delta f(x_i, \beta)}{\delta \beta} = \quad (46) \end{aligned}$$

$$\begin{aligned}
= - \sum_{i=1}^N \begin{pmatrix} 1 \\ x_{i1}^1 \\ \dots \\ x_{in}^n \end{pmatrix} \times \left((1 - (\delta_{\mu_i 0} + \delta_{\mu_i k-1})) \frac{(\operatorname{erf}'(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}'(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))}{(\operatorname{erf}(\frac{a_{\mu_i+1}-f(x_i, \beta)}{\sqrt{2}\sigma}) - \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))} + \right. \\
\left. + (\delta_{\mu_i 0} - \delta_{\mu_i k-1}) \frac{\operatorname{erf}'(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma})}{(1 + \operatorname{erf}(\frac{a_{\mu_i}-f(x_i, \beta)}{\sqrt{2}\sigma}))} \right),
\end{aligned}$$

то построенные оценки также применимы и для полиномиальной регрессии.

Также как и в случае линейной регрессии считаем, что выборка содержит выбросы, т.е., аналогично:

$$y_i^{\tilde{\varepsilon}} = (\xi_i)y_i + (1 - \xi_i)\eta_i, \quad (47)$$

здесь y_i задаются формулой (41).

4 Компьютерные эксперименты

4.1 График рассеяния зависимой переменной и регрессоров

Чтобы зрительно представлять, как выбросы влияют на функцию регрессии, был построен график рассеяния зависимой переменной и регрессоров: $(y_i^{\tilde{\varepsilon}}, x_i)$.

Бралась выборка объема $N = 1000$. Доля выбросов $\tilde{\varepsilon}$ равнялась 0.08. Параметры регрессии выбирались $(90, 4)^T$. Регрессоры x_i выбирались из равномерного распределения $\sim U(-5, 5)$. Ошибки экспериментов подчинялись нормальному закону распределения с параметрами $(0, 16)$. Выбросы подчинялись нормальному распределению с параметрами $(100, 100)$.




Рис. 1: График рассеяния $(y_i^{\tilde{\varepsilon}}, x_i)$

На рисунке 1 видно, что часть аномальных наблюдений сильно отстоит от генеральной совокупности наблюдений и поэтому вносят сильное искажение в результирующие группированные наблюдения, но при этом, по всей видимости, может быть выявлена при переклассификации. Остальная часть аномальных наблюдений "смешивается" с генеральной совокупностью и поэтому плохо выявляется при переклассификации.

4.2 Вариации оценок МНК и М-оценок в случае линейной регрессии с выбросами

Далее было проведено сравнение, как ведет себя классический метод и робастный метод в случае возникновения аномальных наблюдений в выборке.

На следующих двух графиках изображено изменение вариаций М-оценок и МНК оценок при увеличении объема выборки.




Рис. 2: Вариации оценок МНК в зависимости от объема выборки при постоянной доле выбросов



Рис. 3: Вариации оценок М-оценок в зависимости от объема выборки при постоянной доле выбросов

Объем выборки изменялся от $N = 100$ до $N = 1000$. Доля выбросов $\tilde{\varepsilon}$ равнялась 0.08. Параметры регрессии выбирались $(90, 4)^T$. Регрессоры x_i выбирались из равномерного распределения $\sim U(-5, 5)$. Ошибки экспериментов подчинялись нормальному закону распределения с

параметрами $(0, 16)$. Выбросы подчинялись нормальному распределению с параметрами $(100, 100)$.

На графиках видно, что робастные М-оценки в отличие от оценок МНК сходятся с увеличением объема выборки. Рисунок 2 показывает, почему важна задача построения робастных методов оценивания параметров регрессии: классический метод (оценки МНК) не сходится при увеличении объема выборки.

4.3 Вариации оценок без переклассификации

Далее был проведен похожий эксперимент на эксперимент в пункте 4.2, но кроме аномальных наблюдений присутствовало группирование выборки. Использовались построенные ОМП-оценки, но не применялась переклассификация выборки.

Объем выборки N изменялся от $N_1 = 140$ до $N_2 = 300$, при этом выборка дополнялась, а не генерировалась новая. Использовалась модель линейной регрессии. Доля выбросов была постоянна и равнялась $\tilde{\varepsilon} = 0.08$. Регрессоры x_i были из равномерного распределения $U(-5, 5)$. Параметры регрессии были постоянными и равнялись $\beta = (90, 4)^T$. Ошибки экспериментов $\varepsilon_i \sim \mathcal{N}(0, 16)$. На графике изображено изменение вариаций оценок при увеличении объема выборки.




Рис. 4: Зависимость вариаций от размера выборки

С увеличением объема выборки построенные ОМП-оценки сходятся, но так как в выборке присутствуют аномальные наблюдения, скорость сходимости метода невелика и дисперсия вариаций оценок очень большая.

4.4 Графики рассеяния оценок в случае использования метода К-ближайших соседей для переклассификации

Далее к выборке с аномальными наблюдениями с группированием применялась переклассификация, а после этого применялись построенные ОМП-оценки.

На следующих двух графиках (рис. 5 - рис. 6) изображена диаграмма рассеяния, если для переклассификации выборки выбран метод K -ближайших соседей.

Для построения рисунка 5 генерировались выборки объема $N = 1000$. Доля выбросов $\tilde{\varepsilon}$ равнялась 0.08. Параметры регрессии выбирались $(90, 4)^T$. Регрессоры x_i выбирались из равномерного распределения $\sim U(-5, 5)$. Ошибки экспериментов подчинялись нормальному закону распределения с параметрами $(0, 16)$. Выбросы подчинялись нормальному распределению с параметрами $(100, 100)$.





Рис. 5: График рассеяния $(\hat{\beta}_0, \hat{\beta}_1)$

Для построения рисунка 6 генерировались выборки объема $N = 1000$. Доля выбросов $\tilde{\varepsilon}$ равнялась 0.08. Параметры регрессии выбирались $(90, 4)^T$. Регрессоры x_i выбирались из равномерного распределения $\sim U(-5, 5)$. Ошибки экспериментов подчинялись нормальному закону распределения с параметрами $(0, 16)$. Выбросы подчинялись нормальному распределению с параметрами $(100, 100)$.

Рис. 6: График рассеяния $(\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2)$

На полученных рисунках видно, что оценки параметров получаются близкими при разных выборках.

4.5 Сравнение оценок при переклассификации методом К-ближайших соседей с оценками без переклассификации

Были проведены эксперименты для сравнения эмпирической вариации оценок максимального правдоподобия, когда использовалась переклассификация методом К-ближайших соседей и когда не использовалась. При этом на каждой итерации выборка увеличивалась.

Объем выборки N изменялся от $N_1 = 100$ до $N_2 = 400$, при этом выборка дополнялась, а не генерировалась новая. Использовалась модель линейной регрессии. Доля выбросов была постоянна и равнялась $\tilde{\varepsilon} = 0.08$. Параметры регрессии были постоянными и равнялись $\beta = (90, 4)^T$. Регрессоры x_i были из равномерного распределения $U(-5, 5)$, ошибки экспериментов $\varepsilon_i \sim \mathcal{N}(0, 16)$. В методе, где использовалась переклассификация, величина K выбиралась: $K = 10$.

Таблица 1: Параметры модели и оценок экспериментов

Параметры программы	
Переменная	значение
Размер выборки N	от 100 до 400
Доля выбросов $\tilde{\varepsilon}$	0.08
Параметры регрессии β	(90, 4)
Регрессоры x_i	$\sim U(-5, 5)$
ε_i	$\sim \mathcal{N}(0, 16)$
η_i	$\sim \mathcal{N}(100, 100)$
В методе, с переклассификацией величина K	10

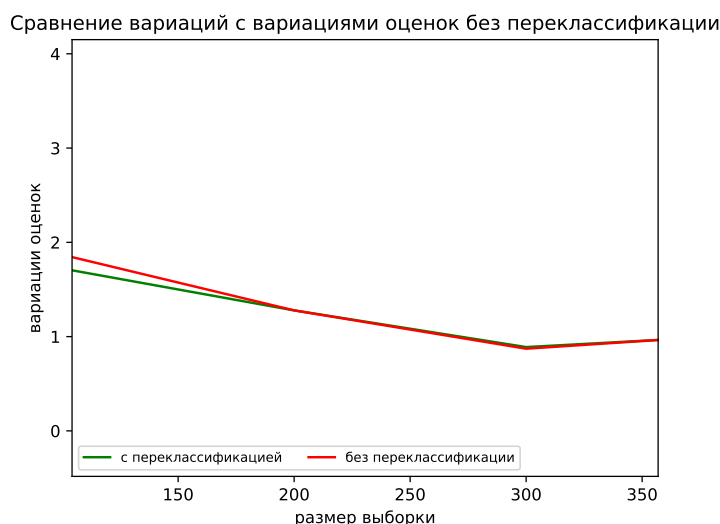


Рис. 7: Сравнение вариаций оценок максимального правдоподобия когда используется и не используется переклассификация

4.6 Сравнительный анализ оценок максимального правдоподобия с альтернативной

4.6.1 Эксперимент с изменением объема выборки

В следующем эксперименте был произведен сравнительный анализ вариаций ОМП-оценок с МНК оценками в зависимости от объема выборки.

Объем выборки N изменялся от $N_1 = 100$ до $N_2 = 500$, при этом выборка дополнялась, а не генерировалась новая. Использовалась модель линейной

регрессии. Доля выбросов была постоянна и равнялась $\tilde{\varepsilon} = 0.08$. Параметры регрессии были постоянными и равнялись $\beta = (90, 4)^T$. Регрессоры x_i были из равномерного распределения $U(-5, 5)$, ошибки экспериментов $\varepsilon_i \sim \mathcal{N}(0, 16)$. Для переклассификации использовался метод K -ближайших соседей.

Таблица 2: Параметры модели и оценок

Параметры программы	
Переменная	значение
Размер выборки N	от 100 до 500
Доля выбросов $\tilde{\varepsilon}$	0.08
Параметры регрессии β	$(90, 4)$
Регрессоры x_i	$\sim U(-5, 5)$
ε_i	$\sim \mathcal{N}(0, 16)$
η_i	$\sim \mathcal{N}(100, 100)$
Величина K	10




Рис. 8: Сравнение вариаций оценок

При сравнении графиков вариаций (рис.8) можно сделать вывод, что ОМП дают лучший результат,

4.6.2 Эксперимент с полиномиальной регрессией

Был проведен эксперимент с полиномиальной регрессией. Использовались те же параметры модели (таблица 3), объем выборки N изменялся от 100 до 1000:




Рис. 9: Вариации оценок в случае полиномиальной регрессии

Оба метода имели схожее поведение при изменении объема выборки, но построенные оценки максимального правдоподобия стабильно показывали лучший результат.

4.7 Эксперименты с изменением уровня переклассификации выборки для метода K -ближайших соседей

В ходе дипломной работы были построены эксперименты с изменением величины K для метода K -ближайших соседей, используемого в переклассификации.

Объем выборки N был постоянным: $N = 500$. Использовалась модель линейной регрессии. Доля выбросов была постоянна и равнялась $\tilde{\varepsilon} = 0.08$. Параметры регрессии были постоянными и равнялись $\beta = (90, 4)^T$. Регрессоры x_i были из равномерного распределения $U(-5, 5)$, ошибки экспериментов $\varepsilon_i \sim \mathcal{N}(0, 16)$. Величина K менялась от 10 до 40.

Таблица 3: Параметры модели и оценок экспериментов с переклассификацией выборки

Параметры программы	
Переменная	значение
Размер выборки N	500
Доля выбросов $\tilde{\varepsilon}$	0.08
Параметры регрессии β	(90, 4)
Регрессоры x_i	$\sim U(-5, 5)$
ε_i	$\sim \mathcal{N}(0, 16)$
η_i	$\sim \mathcal{N}(100, 100)$
Величина K	от 10 до 40




Рис. 10: Зависимость вариаций от K – числа соседей, используемого в переклассификации выборки

В результате получилось, что при увеличении константы K точность оценки параметров растёт.

4.8 Эксперименты с изменением K для Local outlier factor, используемого в переклассификации

В ходе экспериментов была построена таблица, где выписаны K для выборки определенного объема с определенной длиной интервала, то есть такую величину K , при которой количество неверных классов после переклассификации не более чем такое количество до переклассификации (значения получены опытным путём). Доля выбросов была постоянна и

равнялась $\tilde{\varepsilon} = 0.08$. Параметры регрессии были постоянными и равнялись $\beta = (90, 4)^T$. Регрессоры x_i были из равномерного распределения $U(-5, 5)$, ошибки экспериментов $\varepsilon_i \sim \mathcal{N}(0, 16)$.

Таблица 4: Подходящие значения K для выборки определенного объема с определенной длиной интервала

Объем выборки	длина интервала	величина K
1000	2.0	2
1000	3.0	4
1000	4.0	4
3000	1.0	2
3000	1.5	2
3000	1.75	3
3000	2.0	5
3000	4.0	7
10000	1.0	2
10000	1.5	3
10000	2.0	6
10000	4.0	8

Далее приведен пример получаемых в ходе экспериментов значений. было смоделировано 10^5 наблюдений. Процент аномальных наблюдений: 8%. Константа K равнялась 3.

```
modulated with outlier count: 8047
fit: classified
wrong outliers: 7987
fit: reclassifier scored 0.925034 on learning set:
fit: reclassified 10

fit: classified

Classes differ with/without outliers when without reclassification: 7604
Classes differ with/without outliers when with reclassification: 7582
```

Число 8047 - количество выбросов в выборке.

Число 7987 - количество ошибочно определенных выбросов (то есть ошибки рода: отнести выбросы к истинным значениям или истинные значения к выбросам). Хотим, чтобы было по крайней мере меньше предыдущего значения.

Число 7604 - количество неверных значений изначально, то есть неверных значений, полученных извне (это число может быть меньше 8047 так как при достаточно широких классах выбросы могли попасть в нужный класс)

Число 7582 - результат переклассификации, который мы хотим получить меньше предыдущего числа (7604). Чем меньше - тем лучше.

4.9 Влияние переклассификации методом LOF на вариации оценок

На следующем графике показано изменение вариаций ОМП и ОМП с переклассификацией методом, где используется локальный уровень выброса и случайный лес. Объем выборки изменялся от $N = 500$ до $N = 800$. Доля выбросов $\tilde{\varepsilon}$ равнялась 0.08. Параметры регрессии выбирались $(90, 4)^T$. Регрессоры x_i выбирались из равномерного распределения $\sim U(-5, 5)$. Ошибки экспериментов подчинялись нормальному закону распределения с параметрами $(0, 16)$. Выбросы подчинялись нормальному распределению с параметрами $(100, 100)$.




Рис. 11: Зависимость вариаций от размера выборки

На данном графике видно, что возможна сходимость оценок, а также в целом видно, что переклассификация очень хорошо влияет на точность результатов.

Заключение

В ходе выполнения дипломной работы были получены следующие результаты: была рассмотрена математическая модель линейной регрессии с выбросами при наличии группирования наблюдений; были описаны основные методы оценивания параметров линейной регрессии при наличии выбросов: оценки МНК, М-оценки; были построены оценки параметров линейной регрессии при наличии группирования наблюдений по методу максимального правдоподобия; были проведены компьютерные эксперименты в которых построенные оценки применялись к модельным данным; результаты экспериментов показали, что построенные оценки могут быть состоятельными.

В ходе дипломной работы был проведен аналитический обзор литературы методов статистического анализа данных при наличии классифицированных наблюдений с искажениями. В результате был реализован альтернативный метод - *метод наименьших квадратов по центрам интервалов*.

Был проведен сравнительный анализ альтернативного метода с оценками максимального правдоподобия. Оценки максимального правдоподобия с переклассификацией выборки показали наилучшие результаты.

Над оценками максимального правдоподобия с переклассификацией выборки были осуществлены эксперименты, в которых изменялась константа K для метода K -ближайших соседей (см. п. 4.7). Выяснилось, что увеличение константы K повышает точность аппроксимации.

Реализованные методы максимального правдоподобия с переклассификацией и МНК по серединам интервалов были обобщены на случай полиномиальной регрессии.

Был построен еще один способ переклассификации выборки, который показывает лучший результат по сравнению с методом K -ближайших соседей (по проведенным экспериментам оказалось, что метод в среднем правильно исправляет в 10 раз больше аномальных наблюдений).

Список литературы

- [1] Хьюбер Дж П. *Робастность в статистике: пер. с англ.* – М.: Мир, 1984. – 304 с.
- [2] Харин Ю.С., Зуев Н.М., Жук Е.Е. *Теория вероятностей, математическая и прикладная статистика: учебник* – Минск: БГУ, 2011. – 463 с.
- [3] Е. С Агеева, чл.-корр. НАН Беларуси Ю.С. Харин *Состоятельность оценки максимального правдоподобия параметров множественной регрессии по классифицированным наблюдениям*
- [4] John Fox, Sanford Weisberg *Robust Regression* – October 8, 2013
- [5] А.В. Омельченко *Робастное оценивание параметров полиномиальной регрессии второго порядка* – Харьковский национальный университет радиоэлектроники, Украина, 2009
- [6] Özlem Gürünlü Alma *Comparison of Robust Regression Methods in Linear Regression* – Int. J. Contemp. Math. Sciences, Vol. 6, 2011, no. 9, 409 - 421 с.
- [7] Sergei Winitzki *A handy approximation for the error function and its inverse.*
- [8] Мандрик П.А., Репников В.И., Фалейчик Б.В., *Численные методы* [Электронный ресурс].
- [9] Paolo Giordani *Linear regression analysis for interval-valued data based on the Lasso technique.* – Department of Statistical Sciences Sapienza University of Rome
- [10] Masahiro Inuiguchi, Tetsuzo Tanino, *interval linear regression methods based on minkowski difference a bridge between traditional and interval linear regression models.* – KYBERNETIKA, volume 42, 2006 , number 4, pages 423 - 440
- [11] Nelson, W., Hahn, G.J. *Technometrics.* volume 14, 1972, pages 247–269.
- [12] Markus M. Breunig, Hans-Peter Kriegel, Raymond T. Ng, Jörg Sander *LOF: Identifying Density-Based Local Outliers.* – Proc. ACM SIGMOD 2000 Int. Conf. On Management of Data, pages 93–104, Dallas, TX, 2000
- [13] Nathan L. Knight, Jinling Wang *A Comparison of Outlier Detection Procedures and Robust Estimation Methods in GPS Positioning.* The University of New South Wales, Journal of Navigation 62(04):699-709, October 2009
- [14] N. S. Altman, *An introduction to kernel and nearest-neighbor nonparametric regression.* The American Statistician. 46 (3): 175–185, 1992.

- [15] L. Breiman. *Random Forests*. Machine Learning. 45 (1): 5–32, 2001.

Приложение

Метод наименьших квадратов по центрам интервалов

```
class ApproximationGEMModelNaive(ApproximationGEMModelRedesigned):
    def fit(self):
        self.classify()

        def ex_generator(mu_data):
            for i in range(0, self.endogen.size):
                if mu_data[i] is None:
                    continue
                a_mu_i_plus_1 = mu_data[i] * Defines.INTERVAL_LENGTH
                a_mu_i = mu_data[i] * Defines.INTERVAL_LENGTH - Defines.INTERVAL_LENGTH
                yield (a_mu_i_plus_1 + a_mu_i) / 2

        naive_ex_data_positive = np.fromiter(ex_generator(self._np_freq_positive), float)
        naive_ex_data_negative = np.fromiter(ex_generator(self._np_freq_negative), float)

        naive_ex_data_full = np.append(naive_ex_data_positive, naive_ex_data_negative)

        z, resid, rank, sigma = np.linalg.lstsq(self.exogen, naive_ex_data_full, rcond=None)
        return z
```

Моделирование полиномиальной регрессии:

```
def modulate_polynomial_regression(regression_sample_quintity, regression_outlier_percentage):
    regression_parameters = ACCURATE_RESULT
    _x_points = np.zeros(shape=[regression_sample_quintity, len(regression_parameters)])
    _y_points = np.zeros(shape=regression_sample_quintity)

    def np_random_polynomial(size):
        _res = np.zeros(size)
        for i in range(0, size):
            _res[i] = random.uniform(-5, 5) ** (i + 1)

        return _res

    for i in range(0, regression_sample_quintity):
        _x_points[i] = np.append(np.ones(1), np_random_polynomial(len(ACCURATE_RESULT) - 1))
        if random.random() > regression_outlier_percentage / 100:
            _y_points[i] = (_x_points[i] * ACCURATE_RESULT) + np.random.normal(0, 4)
        else:
            _y_points[i] = np.random.normal(100.0, 15.0, size=1)

    return _x_points, _y_points
```

Моделирование линейной регрессии:

```
def modulateRegression(regression_sample_quintity, regression_outlier_percentage):
    regression_parameters = ACCURATE_RESULT
    _x_points = np.zeros(shape=[regression_sample_quintity, len(regression_parameters)])
    _y_points = np.zeros(shape=regression_sample_quintity)

    for i in range(0, regression_sample_quintity):
        if random.random() > regression_outlier_percentage / 100:
            _x_points[i] = np.append(np.ones(1), np.random.uniform(-5, 5, size=len(regression_parameters) - 1))
            _y_points[i] = (_x_points[i] * regression_parameters) + np.random.normal(0, 4)
        else:
            _x_points[i] = np.append(np.ones(1), np.random.uniform(-5, 5, size=len(regression_parameters) - 1))
            _y_points[i] = np.random.normal(100.0, 15.0, size=1)

    return _x_points, _y_points
```

Метод наименьших квадратов по центрам интервалов:

```
def fit_data_naive_classic():
    sample_sizes = []
    all_results_classic = []
    all_results_naive = []
    for sample_size in range(SAMPLE_SIZE_MIN, SAMPLE_SIZE_MAX+1, SAMPLE_SIZE_STEP):
```

```

successful_fit = False
while not successful_fit:
    x_points, y_points = modulateRegression(sample_size, OUTLIER_PERCENTAGE)
    approx_model = groupingEstimates.GEM(x_points, y_points)
    approx_model_naive = groupingEstimatesNaive.GEM_N(x_points, y_points)
    try:
        result = approx_model.fit()
        print("GEM {}".format(result))
        result_naive = approx_model_naive.fit()
        print("GEM_N {}".format(result_naive))

        successful_fit = True

        all_results_classic.append(result)
        all_results_naive.append(result_naive)
        sample_sizes.append(sample_size)
    except KeyboardInterrupt:
        print("stopping...")
        np.save(NP_DATA_PATH + "gem_res_classic", all_results_classic)
        np.save(NP_DATA_PATH + "gem_res_naive", all_results_naive)
        np.save(NP_DATA_PATH + "gem_sizes", sample_sizes)
        quit()
    except Exception as e:
        print(e)
np.save(NP_DATA_PATH + "gem_res_classic", all_results_classic)
np.save(NP_DATA_PATH + "gem_res_naive", all_results_naive)
np.save(NP_DATA_PATH + "gem_sizes", sample_sizes)

```

График с разным объемом выборки:

```

def plot_with_different_sample_size():
    sample_sizes = []
    all_results_with_classification = []
    all_results_without_classification = []

    x_points = None
    y_points = None

    for sample_size in range(SAMPLE_SIZE_MIN, SAMPLE_SIZE_MAX+1, SAMPLE_SIZE_STEP):
        successful_fit = False
        while not successful_fit:
            x_points_t, y_points_t = modulateRegression(sample_size, OUTLIER_PERCENTAGE)

            if x_points is None or y_points is None:
                x_points = x_points_t
                y_points = y_points_t
            else:
                x_points = np.append(x_points, x_points_t, axis=0)
                y_points = np.append(y_points, y_points_t, axis=0)

            approx_model = groupingEstimates.GEM(x_points, y_points)
            try:
                result = approx_model.fit()
                print("GEM {}".format(result))
                result_without = approx_model.fit_without_reclassification()
                print("GEM_without {}".format(result_without))

                successful_fit = True

                all_results_with_classification.append(result)
                all_results_without_classification.append(result_without)
                sample_sizes.append(sample_size)
            except KeyboardInterrupt:
                print("stopping...")
                np.save(NP_DATA_PATH + "gem_res_with", all_results_with_classification)
                np.save(NP_DATA_PATH + "gem_res_without", all_results_without_classification)
                np.save(NP_DATA_PATH + "gem_sizes_with_without", sample_sizes)
                quit()
            except Exception as e:
                print(e)
        np.save(NP_DATA_PATH + "gem_res_with", all_results_with_classification)
        np.save(NP_DATA_PATH + "gem_res_without", all_results_without_classification)
        np.save(NP_DATA_PATH + "gem_sizes_with_without", sample_sizes)

```

График с разным уровнем переклассификации:

```
def plot_with_different_reclassification_level():
    reclassification_levels = []
    all_results_with_classification = []
    recl_level_min = 10
    recl_level_max = 40

    x_points, y_points = modulateRegression(500, OUTLIER_PERCENTAGE)

    for recl_level in range(recl_level_min, recl_level_max + 1, 2):
        GroupingEstimatesDefines.RECLASSIFICATION_LEVEL = recl_level

        successful_fit = False
        while not successful_fit:
            approx_model = groupingEstimates.GEM(x_points, y_points)
            try:
                result = approx_model.fit()
                print("GEM {}".format(result))

                successful_fit = True

                all_results_with_classification.append(result)
                reclassification_levels.append(recl_level)
            except KeyboardInterrupt:
                print("stopping...")
                np.save(NP_DATA_PATH + "gem_with_dif_level_results", all_results_with_classification)
                np.save(NP_DATA_PATH + "gem_with_dif_level_levels", reclassification_levels)
                quit()
            except Exception as e:
                print(e)
        np.save(NP_DATA_PATH + "gem_with_dif_level_results", all_results_with_classification)
        np.save(NP_DATA_PATH + "gem_with_dif_level_levels", reclassification_levels)
```